

## homework 2-2

---

余苏皓 2152199

### 问题描述:

理论和实验证明, 一个两层的ReLU网络可以模拟任何函数。请自行定义一个函数, 并使用基于ReLU的神经网络来拟合此函数。

---

### 理论证明:

证明:

#### 1. 任意连续函数都可以由分段线性函数逼近

对于一个闭区间上的连续函数, 可以构造一系列多项式, 使得这些多项式在该闭区间上的一致逼近误差可以任意小。

具体来说, 证明过程如下:

1. 对于一个闭区间 $[a, b]$ 上的连续函数  $f(x)$ , 可以构造一个伯恩斯坦多项式序列  $B_n(x)$ , 使得  $B_n(x)$  在  $[a, b]$  上一致收敛于  $f(x)$ 。
2. 伯恩斯坦多项式是分段线性函数的线性组合。因此, 对于任意给定的  $\epsilon > 0$ , 都存在一个自然数  $N$ , 使得对于所有  $n \geq N$ , 都有:

$$|f(x) - B_n(x)| < \epsilon$$

它表明, 分段线性函数可以用来逼近任意连续函数, 并且逼近精度可以任意高。

#### 2. 两层ReLU网络可以表示任意分段线性函数

两层ReLU网络可以表示如下形式:

$$f(x) = w_2 \sigma(w_1 x + b_1) + b_2$$

其中,  $w_1$  和  $w_2$  是权重矩阵,  $b_1$  和  $b_2$  是偏置向量,  $\sigma(x)$  是ReLU激活函数。

ReLU激活函数定义如下:

$$\sigma(x) = \max(0, x)$$

对于任意分段线性函数, 都可以将其表示为一系列ReLU函数的组合。例如, 对于分段线性函数:

$$f(x) = \begin{cases} 0 & x < c \\ x & c \leq x < d \\ d - c & x \geq d \end{cases}$$

可以将其表示为以下ReLU函数的组合:

$$f(x) = \sigma(x - c) - \sigma(x - d)$$

因此, 可以用两层ReLU来拟合任意的分段函数

## 实验证明：

### 一、函数定义

可更改需要拟合的函数，本实验测试下面这个多项式函数：

$$2x^2 - 3x + 1$$

代码如下：

```
def fit_function(x):  
    return 2 * x**2 - 3 * x + 1
```

### 二、数据采集

1. **设置随机种子:** 为了保证每次运行代码的结果一致，代码设置了随机种子为 0。
2. **生成数据:**
  - 使用 `np.random.uniform` 函数生成 100 个随机数，范围为 `[-1, 1]`，并将其赋值给 `x` 变量。
  - 使用 `fit_function` 函数计算 `x` 对应的真实值，并加入随机噪声，模拟真实数据中的误差。将结果赋值给 `y` 变量。

```
np.random.seed(0)  
num_points = 100  
X_train = np.random.uniform(-1, 1, num_points)  
Y_train = fit_function(X_train) + np.random.normal(0, 0.1, num_points)  
  
X_test = np.random.uniform(-1, 1, num_points)  
Y_test = fit_function(X_test) + np.random.normal(0, 0.1, num_points)
```

### 三、模型描述

#### 定义网络结构和初始化参数

1. **设置超参数:**
  - `input_size`: 输入数据的维度，在本例中为 1，表示输入数据是一个单变量。
  - `hidden_size`: 隐藏层的节点数，在本例中为 100，表示隐藏层有 100 个神经元。
  - `output_size`: 输出数据的维度，在本例中为 1，表示输出数据是一个单变量。
2. **初始化权重和偏置:**
  - 使用 `np.random.randn` 函数生成随机权重矩阵 `w1` 和 `w2`，分别用于连接输入层和隐藏层，以及隐藏层和输出层。
  - 使用 `np.zeros` 函数生成零偏置向量 `b1` 和 `b2`，分别用于隐藏层和输出层。

```

input_size = 1
hidden_size = 100
output_size = 1

np.random.seed(0)
w1 = np.random.randn(hidden_size, input_size)
b1 = np.zeros((hidden_size, 1))
w2 = np.random.randn(output_size, hidden_size)
b2 = np.zeros((output_size, 1))

```

## 定义ReLU函数

ReLU函数的公式：

$$ReLU(x) = \max(0, x)$$

```

def relu(x):
    return np.maximum(0, x)

```

## 训练网络

### 1. 定义超参数:

- `num_epochs`: 训练迭代次数。
- `learning_rate`: 学习率，控制参数更新的幅度。

### 2. 训练循环:

- 遍历所有训练迭代周期 (epoch) :
  - 前向传播
  - 计算损失
    - 计算均方误差损失: `loss = np.mean((A2 - Y_train.reshape(1, -1))**2)`

$$MSE = \frac{1}{N} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$

- 使用梯度下降法更新权重和偏置
- 每 50 个迭代周期打印一次损失值

```

for epoch in range(num_epochs):
    # 前向传播
    Z1 = np.dot(w1, X_train.reshape(1, -1)) + b1
    A1 = relu(Z1)
    Z2 = np.dot(w2, A1) + b2
    A2 = Z2

    # 计算损失
    loss = np.mean((A2 - Y_train.reshape(1, -1))**2)

    # 反向传播
    dA2 = 2 * (A2 - Y_train.reshape(1, -1))

```

```

dz2 = dA2
dw2 = np.dot(dz2, A1.T)
db2 = np.sum(dz2, axis=1, keepdims=True)
dA1 = np.dot(w2.T, dz2)
dz1 = dA1 * (z1 > 0)
dw1 = np.dot(dz1, X_train.reshape(1, -1).T)
db1 = np.sum(dz1, axis=1, keepdims=True)

# 更新参数
w1 -= learning_rate * dw1
b1 -= learning_rate * db1
w2 -= learning_rate * dw2
b2 -= learning_rate * db2


# 打印损失
if epoch % 50 == 0:
    print(f"Epoch {epoch}, Loss: {loss}")

```

## 四、拟合效果

### 1. 训练集loss

最后一轮训练的Loss: 0.021899413498240473



### 2. 测试集拟合效果

Test Loss: 0.030224253171291456

下图可视化结果可以看出效果非常好

True vs Predicted Function

